
Klasifikasi Sampah Organik dan Anorganik Menggunakan Algoritma CNN

Michael Emmanuel Purba^{1*}, Angga Zefanya Situmorang², Geby Laurent Br Ginting³, Muhammad Wahyu Pratama Lubis⁴

^{1*}Program Studi Teknik Informatika, Universitas Mikroskil, Medan, Sumatera Utara

²Program Studi Teknik Informatika, Universitas Mikroskil, Medan, Sumatera Utara

³Program Studi Teknik Informatika, Universitas Mikroskil, Medan, Sumatera Utara

⁴Program Studi Teknik Informatika, Universitas Mikroskil, Medan, Sumatera Utara

Email: ^{1*}211111304@students.mikroskil.co.id, ²211111287@students.mikroskil.co.id,
³211111201@students.mikroskil.co.id, ⁴211110731@students.mikroskil.co.id

(Naskah masuk: dd mmm yyyy, direvisi: dd mmm yyyy, diterima: dd mmm yyyy)

Abstrak

Penelitian ini mengembangkan sistem klasifikasi sampah menggunakan algoritma Convolutional Neural Network (CNN) untuk membedakan sampah organik dan anorganik. Arsitektur CNN yang digunakan terdiri dari input layer berukuran 150 x 150 x 3, tiga lapisan konvolusi dengan filter 3x3 yang jumlahnya bertambah secara bertahap (32, 64, dan 128), dilengkapi dengan fungsi aktivasi ReLU dan lapisan MaxPooling 2x2. Model juga menggunakan dense layer dengan 128 neuron, dropout 0.5, dan output layer dengan aktivasi sigmoid. Dalam proses pelatihan, model dikompilasi menggunakan optimizer Adam dengan learning rate 0.001 dan binary crossentropy sebagai loss function. Hasil evaluasi menunjukkan bahwa model mencapai akurasi yang sangat baik sebesar 90,53% pada data uji, membuktikan efektivitas model dalam mengklasifikasikan sampah. Tingkat akurasi yang tinggi ini menunjukkan bahwa arsitektur CNN yang dirancang mampu mempelajari dan mengenali pola-pola penting dari citra sampah dengan baik. Penelitian ini memberikan kontribusi signifikan dalam pengembangan sistem pemilahan sampah otomatis yang dapat membantu meningkatkan efisiensi pengelolaan sampah. Model yang dikembangkan memiliki potensi besar untuk diimplementasikan dalam aplikasi praktis dan dapat diandalkan untuk sistem klasifikasi sampah yang efektif.

Kata Kunci: Convolutional Neural Network (CNN), Klasifikasi Sampah, Deep Learning, Pengolahan Citra Digital, Sistem Pemilahan Otomatis.

Classification of Organic and Inorganic Waste Using CNN Algorithm

Abstract

This research develops a waste classification system using the Convolutional Neural Network (CNN) algorithm to distinguish between organic and inorganic waste. The CNN architecture used consists of an input layer with dimensions of 150 x 150 x 3, three convolutional layers with 3x3 filters that gradually increase in number (32, 64, and 128), equipped with ReLU activation function and 2x2 MaxPooling layer. The model also uses a dense layer with 128 neurons, 0.5 dropout, and an output layer with sigmoid activation. In the training process, the model was compiled using Adam optimizer with a learning rate of 0.001 and binary crossentropy as the loss function. The evaluation results show that the model achieved excellent accuracy of 90.53% on test data, proving the model's effectiveness in classifying waste. This high level of accuracy indicates that the designed CNN architecture is capable of learning and recognizing important patterns from waste images well. This research makes a significant contribution to the development of automatic waste sorting systems that can help improve waste management efficiency. The developed model has great potential to be implemented in practical applications and can be relied upon for an effective waste classification system.

Keywords: Convolutional Neural Network (CNN), Waste Classification, Deep Learning, Digital Image Processing, Automatic Sorting System.

I. PENDAHULUAN

Sampah merupakan permasalahan yang dihadapi setiap negara. Setiap tahun jumlah dan jenis sampah meningkat seiring dengan bertambahnya jumlah penduduk. Di Indonesia, pada tahun 1990, 220 juta penduduk perkotaan menghasilkan kurang lebih 300.000-ton sampah per hari. Tahun 2000, 2,9 miliar orang yang tinggal di perkotaan menghasilkan 3 juta ton limbah sampah per hari. Pada tahun 2025 diperkirakan akan terus meningkat mencapai puluhan juta ton sampah per harinya [1]. Permasalahan sampah merupakan salah satu permasalahan lingkungan di masyarakat yang perlu ditangani dengan benar. Menurut World Health Organization (WHO) sampah adalah sesuatu yang sudah tidak dapat digunakan lagi, tidak dipakai, tidak disenangi, atau segala sesuatu yang dibuang berasal dari kegiatan manusia dan tidak terjadi sendirinya [2].

Sisa-sisa dari proses produksi baik industri ataupun rumah tangga yang sudah tidak terpakai tersebut biasa kita sebut sebagai sampah, dimana pada umumnya di Indonesia dikelompokkan menjadi 2 jenis, yaitu sampah anorganik dan sampah organik. Sampah yang berasal dari makhluk hidup merupakan sampah organik. Sampah organik mudah membusuk atau terurai hanya dalam waktu kurang dari 6 bulan. Sampah yang berasal dari sumber daya yang tidak dapat diperbaharui adalah sampah anorganik. Sampah ini memiliki ciri sulit terurai sehingga butuh waktu hingga puluhan tahun agar dapat terurai dengan tanah. Di Indonesia jumlah sampah yang dihasilkan dapat mencapai sekitar 11,330 ton/hari. Jika jumlah penduduk Indonesia di desa mencapai 128,5 juta jiwa dan di kota mencapai 126,3 juta jiwa, maka rata-rata setiap orang menghasilkan sampah sekitar 0,05 kg setiap harinya [3].

Pemilahan sampah ditingkat rumah tangga adalah salah satu kegiatan yang direkomendasikan oleh UU No. 18 tahun 2008 tentang pengelolaan sampah. Pemilahan sampah itu sederhana, tapi efeknya cukup besar. Pemilahan sampah sangat membantu proses pengumpulan dan daur ulang terhadap sampah-sampah yang masih dapat dimanfaatkan kembali [4]. Salah satu aspek penting dalam pengelolaan sampah adalah pengelompokan sampah menjadi sampah organik dan anorganik. Klasifikasi yang efektif ini memungkinkan penerapan praktik daur ulang yang lebih efisien, meminimalkan dampak negatif terhadap lingkungan, dan memberikan dasar bagi pengembangan kebijakan pengelolaan limbah berkelanjutan. Dalam konteks ini, teknik kecerdasan buatan, khususnya Convolutional Neural Network (CNN) merupakan suatu jenis algoritma dalam deep learning yang dapat menerima gambar sebagai sebuah masukan (input) dan mengolahnya dengan tujuan untuk mengidentifikasi objek [5].


Convolutional Neural Network merupakan perkembangan dari metode ANN (Artificial Neural Network) yang berfokus pada pemrosesan gambar, video, dan suara. Convolutional Neural Network (CNN) merupakan salah satu

metode deep learning yang dapat digunakan untuk mendeteksi dan mengenali sebuah objek pada sebuah gambar digital. CNN telah banyak diterapkan diberbagai bidang diantaranya untuk mendeteksi pengenalan karakter plat nomor kendaraan [6].

Penelitian ini akan menganalisis model CNN yang paling cocok untuk mengoptimalkan klasifikasi pemilahan sampah. Dengan algoritme ini, diharapkan proses pemisahan sampah secara otomatis dapat diterapkan dalam sistem. Tujuan dari penelitian ini adalah untuk mempercepat dan mempermudah proses pemilahan sampah dalam rangka mendukung tahapan daur ulang.


II. METODE PENELITIAN

Penelitian ini diawali dengan pengumpulan data berupa gambar yang akan digunakan dalam pelatihan model klasifikasi menggunakan Convolutional Neural Network (CNN). Tahap berikutnya adalah pre-processing, yaitu proses membersihkan dan menormalkan data melalui teknik seperti resize, augmentasi, dan normalisasi agar data siap digunakan dalam pelatihan. Setiap gambar kemudian diberi label yang sesuai, misalnya "Organik" atau "Anorganik," untuk dijadikan target klasifikasi. Setelah itu, arsitektur CNN dirancang dengan menentukan jumlah lapisan konvolusi, pooling, dan pengaturan hyperparameter yang optimal. Model dilatih menggunakan data yang telah diproses guna mengoptimalkan bobot dan bias, sehingga dapat melakukan klasifikasi dengan akurat. Proses penelitian ini diakhiri dengan evaluasi performa model untuk mengukur keakuratannya dalam klasifikasi. langkah-langkah dalam penelitian ini dapat dilihat pada Gambar 1.



Gambar 1. Tahapan Penelitian

1. Pengumpulan Data : Penelitian ini melibatkan data rill yang diambil secara langsung dan data dari situs resmi kaggle. gambar sampah yang digunakan dalam penelitian ini didapatkan dari dataset *Dataset Sampah Organik dan Anorganik* di Kaggle. Dataset ini mencakup berbagai jenis citra sampah organik dan anorganik. Proses pengumpulan data dapat dilihat pada gambar 2.



Gambar 2. Pengumpulan Data

2. Preprocessing : Perancangan preprocessing merupakan sebuah tahap yang harus dilakukan sebelum tahap perancangan arsitektur CNN. Dalam tahap ini, dilakukan augmentasi data. Augmentasi data mampu meningkatkan jumlah data dengan cara memodifikasi data. Proses ini dapat mencegah terjadinya overfitting atau underfitting pada model terlebih pada data dengan jumlah yang sedikit [5].

Preprocessing yang dilakukan adalah normalisasi nilai pixel (rescale=1/255), augmentasi data training dengan teknik rotasi (20°), pergeseran vertikal dan horizontal (0.2), transformasi shear (0.2), zoom (0.2), flip horizontal, dan resize gambar menjadi 150x150 pixel dengan batch size 16.

3. Pemberian Label : Pada tahap ini, setelah melalui proses pre-processing, dataset diberi label untuk memisahkan data ke dalam dua kategori, yaitu organik dan anorganik. Jumlah data organik dan anorganik yang diberi label dapat dilihat pada tabel 1.

Tabel 1. Dataset yang telah diberi label

NO	Class	Train	Test
1	Organik	12565	1401
2	Anorganik	9999	1112
TOTAL		22564	2513

4. Perancangan Arsitektur CNN : Arsitektur Convolutional Neural Network (CNN) yang digunakan dalam penelitian ini dimulai dengan input layer berukuran 150 x 150 x 3, yang dirancang untuk menerima citra berformat RGB. Selanjutnya, model terdiri dari tiga lapisan konvolusi dengan filter 3x3, yang jumlahnya bertambah secara bertahap menjadi 32, 64, dan 128. Setiap lapisan konvolusi dilengkapi dengan fungsi aktivasi ReLU dan diikuti oleh lapisan MaxPooling berukuran 2x2 untuk mengurangi dimensi spasial. Setelah proses konvolusi selesai, data diratakan menggunakan lapisan Flatten untuk mengubah feature map menjadi vektor satu dimensi. Pada fully connected layer, model dilengkapi dengan dense

layer berisi 128 neuron yang menggunakan aktivasi ReLU, disertai dengan dropout sebesar 0.5 untuk mengurangi risiko overfitting. Model ini diakhiri dengan output layer berupa dense layer dengan 1 neuron yang menggunakan fungsi aktivasi sigmoid untuk klasifikasi biner. Model CNN kemudian dikompilasi menggunakan optimizer Adam, binary crossentropy sebagai loss function, dan metrik akurasi sebagai evaluasi performa. Arsitektur CNN yang dibentuk dapat dilihat pada gambar 3.

```
# CNN model definition
model = Sequential([
    Conv2D(32, (3, 3), activation='relu', input_shape=(150, 150, 3)),
    MaxPooling2D((2, 2)),
    Conv2D(64, (3, 3), activation='relu'),
    MaxPooling2D((2, 2)),
    Conv2D(128, (3, 3), activation='relu'),
    MaxPooling2D((2, 2)),
    Flatten(),
    Dense(128, activation='relu'),
    Dropout(0.5),
    Dense(1, activation='sigmoid')
])
```

Gambar 3. Arsitektur CNN

5. Pelatihan Model : Dalam bagian metode penelitian, Model dikompilasi menggunakan optimizer Adam dengan learning rate tertentu dan loss function yang sesuai untuk masalah klasifikasi biner, serta menggunakan akurasi sebagai metrik evaluasi. Untuk pelatihan model, digunakan generator data untuk memuat data pelatihan dan data uji secara efisien, dengan jumlah steps_per_epoch tertentu dan model dilatih selama beberapa epoch, serta menggunakan data uji untuk memvalidasi model selama pelatihan. Setelah pelatihan, model dievaluasi menggunakan data uji, dan hasil evaluasi mengembalikan nilai loss dan akurasi pada data uji, yang kemudian dicetak dalam bentuk persentase. Pelatihan model dapat dilihat pada gambar 4.

```
model.compile(optimizer=Adam(learning_rate=0.001),
              loss='binary_crossentropy',
              metrics=['accuracy'])

# Training the model with fewer steps per epoch and more epochs
steps_per_epoch = 200
history = model.fit(
    train_generator,
    steps_per_epoch=steps_per_epoch,
    epochs=100,
    validation_data=test_generator
)

# Evaluate the model
test_loss, test_accuracy = model.evaluate(test_generator)
print(f"Test Accuracy: {test_accuracy * 100:.2f}%")
```

Gambar 4. Pelatihan Model

III. HASIL DAN PEMBAHASAN

Pada Penelitian ini, arsitektur Convolutional Neural Network (CNN) yang digunakan dimulai dengan input layer berukuran $150 \times 150 \times 3$, yang dirancang untuk menerima citra berformat RGB. Model terdiri dari tiga lapisan konvolusi dengan filter 3×3 , yang jumlahnya bertambah secara bertahap menjadi 32, 64, dan 128. Setiap lapisan konvolusi dilengkapi dengan fungsi aktivasi ReLU dan diikuti oleh lapisan MaxPooling berukuran 2×2 untuk mengurangi dimensi spasial. Setelah proses konvolusi selesai, data diratakan menggunakan lapisan Flatten untuk mengubah feature map menjadi vektor satu dimensi. Pada fully connected layer, model dilengkapi dengan dense layer berisi 128 neuron yang menggunakan aktivasi ReLU, disertai dengan dropout sebesar 0.5 untuk mengurangi risiko overfitting. Model ini diakhiri dengan output layer berupa dense layer dengan 1 neuron yang menggunakan fungsi aktivasi sigmoid untuk klasifikasi biner. Model CNN kemudian dikompilasi menggunakan optimizer Adam, binary crossentropy sebagai loss function, dan metrik akurasi sebagai evaluasi performa.

1. Hasil Training Data


Hasil model training yang bertujuan untuk melatih sistem agar dapat mengenali pola sampak organik dan anorganik. Hasil training data pada model CNN dapat dilihat pada gambar 5.

Epoch 90/100	220s 1ststep - accuracy 0.8731 - loss 0.3195 - val_accuracy 0.8715 - val_loss 0.3299
200/200	
Epoch 91/100	220s 1ststep - accuracy 0.8662 - loss 0.3294 - val_accuracy 0.8766 - val_loss 0.4065
200/200	
Epoch 92/100	217s 1ststep - accuracy 0.8673 - loss 0.3372 - val_accuracy 0.8914 - val_loss 0.2734
200/200	
Epoch 93/100	216s 1ststep - accuracy 0.8660 - loss 0.3399 - val_accuracy 0.8989 - val_loss 0.2849
200/200	
Epoch 94/100	218s 1ststep - accuracy 0.8817 - loss 0.3017 - val_accuracy 0.8826 - val_loss 0.2639
200/200	
Epoch 95/100	222s 1ststep - accuracy 0.8798 - loss 0.2966 - val_accuracy 0.8930 - val_loss 0.2909
200/200	
Epoch 96/100	45s 221mstep - accuracy 0.8590 - loss 0.3363 - val_accuracy 0.8890 - val_loss 0.3125
200/200	
Epoch 97/100	217s 1ststep - accuracy 0.8709 - loss 0.3018 - val_accuracy 0.8878 - val_loss 0.2854
200/200	
Epoch 98/100	220s 1ststep - accuracy 0.8687 - loss 0.3300 - val_accuracy 0.9208 - val_loss 0.2186
200/200	
Epoch 99/100	221s 1ststep - accuracy 0.8850 - loss 0.2942 - val_accuracy 0.8942 - val_loss 0.2684
200/200	
Epoch 100/100	224s 1ststep - accuracy 0.8747 - loss 0.3185 - val_accuracy 0.9053 - val_loss 0.2543
200/200	
158/158	40s 252mstep - accuracy 0.9028 - loss 0.2620
Test Accuracy 90.53%	

Gambar 5. Hasil Training Model

Hasil evaluasi model yang ditunjukkan pada Gambar 4 di atas, dapat disimpulkan bahwa arsitektur model CNN yang digunakan terdiri dari input layer berukuran $150 \times 150 \times 3$, tiga lapisan konvolusi dengan jumlah filter yang meningkat, dilanjutkan dengan lapisan MaxPooling, Flatten, dense layer dengan dropout, dan output layer dengan aktivasi sigmoid. Model CNN tersebut dikompilasi menggunakan optimizer Adam, loss function binary crossentropy, dan akurasi sebagai metrik evaluasi. Berdasarkan hasil evaluasi, model mencapai akurasi hingga 90.53% pada data uji, menunjukkan bahwa model CNN yang dilatih mampu mengklasifikasikan objek menjadi dua kelas (organik dan anorganik) dengan tingkat akurasi yang cukup baik. Selain akurasi, hasil evaluasi juga menampilkan nilai loss dan akurasi per epoch, yang dapat digunakan untuk menganalisis tren performa model selama proses pelatihan. Secara keseluruhan, pendekatan menggunakan arsitektur CNN yang dirancang dengan baik dan dilatih dengan parameter yang sesuai telah menghasilkan model klasifikasi dengan performa yang memuaskan pada


dataset yang digunakan dalam penelitian ini. Model accuracy dan loss pada model CNN yang telah dibangun dapat dilihat pada gambar 6.



Gambar 6. Model Accuracy dan model loss

Berdasarkan grafik yang disajikan, dapat dilihat bahwa model menunjukkan tren peningkatan akurasi dan penurunan loss selama proses pelatihan. Akurasi pada data pelatihan cenderung lebih tinggi dan stabil dibandingkan akurasi pada data validasi, meskipun terdapat fluktuasi dalam nilai akurasi. Hal ini mengindikasikan adanya kemungkinan overfitting, di mana model terlalu menyesuaikan diri dengan data pelatihan namun tidak mampu menggeneralisasi dengan baik pada data validasi. Sementara itu, nilai loss pada data pelatihan juga cenderung lebih rendah dibandingkan nilai loss pada data validasi, dengan beberapa puncak yang mengindikasikan ketidakstabilan selama proses pelatihan. Secara umum, grafik menunjukkan bahwa model mengalami peningkatan performa seiring dengan bertambahnya jumlah epoch pelatihan, meskipun masih terdapat ruang untuk perbaikan dalam mempertahankan keseimbangan antara akurasi pada data pelatihan dan validasi.

2. Pengujian Model



Gambar 7. Pengujian Model

Hasil pengujian akhir terhadap model CNN yang dilatih menunjukkan bahwa model telah mencapai akurasi sebesar

90,53% pada data uji. Hasil dari pengujian Model yang telah dilakukan dapat dilihat pada gambar 7.

IV. KESIMPULAN

Hasil pengujian akhir terhadap model CNN yang dilatih menunjukkan performa yang sangat baik dengan mencapai akurasi sebesar 90,53% pada data uji, menandakan bahwa model ini sangat efektif dalam mengklasifikasikan sampah organik dan anorganik. Tingkat akurasi yang tinggi ini membuktikan bahwa arsitektur CNN yang dirancang mampu mempelajari dan mengenali pola-pola penting dari citra sampah dengan baik. Hasil ini juga menunjukkan bahwa model yang dikembangkan memiliki potensi yang besar untuk diimplementasikan dalam sistem pemilahan sampah otomatis, yang dapat membantu meningkatkan efisiensi pengelolaan sampah. Meskipun model telah menunjukkan kinerja yang memuaskan, masih terdapat peluang untuk pengembangan lebih lanjut melalui penambahan dataset dan penyesuaian parameter untuk meningkatkan generalisasi model. Dengan demikian, penelitian ini telah berhasil mengembangkan sebuah sistem klasifikasi sampah yang dapat diandalkan dan siap untuk diimplementasikan

REFERENSI

- [1] K. A. Priana and A. A. I. N. E. Karyawati, "Sistem Pendeteksi Sampah Secara Realtime Menggunakan Metode YOLO," *Jurnal Nasional Teknologi Informasi dan Aplikasinya*, vol. 2, no. 1, pp. 31–36, 2023.
- [2] K. C. A. Unwaru, Sudarti, and Yushardi, "Analisis Pemanfaatan Sampah Organik Dan Anorganik Terhadap Teknologi PLTSa Di Beberapa Kota Besar Di Indonesia," *Jurnal Sains Dan Teknologi*, vol. 5, no. 2, pp. 255–263, 2022.
- [3] F. P. Fantara, D. Syauby, and G. E. Setyawan, "Implementasi Sistem Klasifikasi Sampah Organik dan Anorganik dengan Metode Jaringan Saraf Tiruan Backpropagation," *Jurnal Pengembangan Teknologi Informasi dan Ilmu Komputer (J-PTIIK) Universitas Brawijaya*, vol. 2, no. 11, pp. 5577–5586, 2018.
- [4] R. Khoirunnisa Apriyani, N. Rustanti, D. Puspa Rahayu, and N. Dewi Utami Hamid, "Sosialisasi Pengenalan Dan Pemilahan Jenis Sampah Organik Dan Anorganik Di Panti Asuhan Anak Shaleh," *Jurnal Pengabdian Kepada Masyarakat*, vol. 1, no. 2, pp. 43–60, 2023, doi: 10.59820/pengmas.v1i2.46.
- [5] G. A. Bahagia and M. Akbar, "KLASIFIKASI SAMPAH ORGANIK DAN ANORGANIK MENGGUNAKAN METODE CONVOLUTIONAL NEURAL NETWORK (CNN)," vol. 8, no. 5, pp. 10349–10355, 2024.
- [6] N. H. Harani, C. Prianto, and M. Hasanah, "Deteksi Objek Dan Pengenalan Karakter Plat Nomor Kendaraan Indonesia Menggunakan Metode Convolutional Neural Network (CNN) Berbasis Python," *Jurnal Teknik Informatika*, vol. 11, no. 3, pp. 47–53, 2019, [Online]. Available: <https://ejurnal.ulbi.ac.id/index.php/informatika/article/view/658>